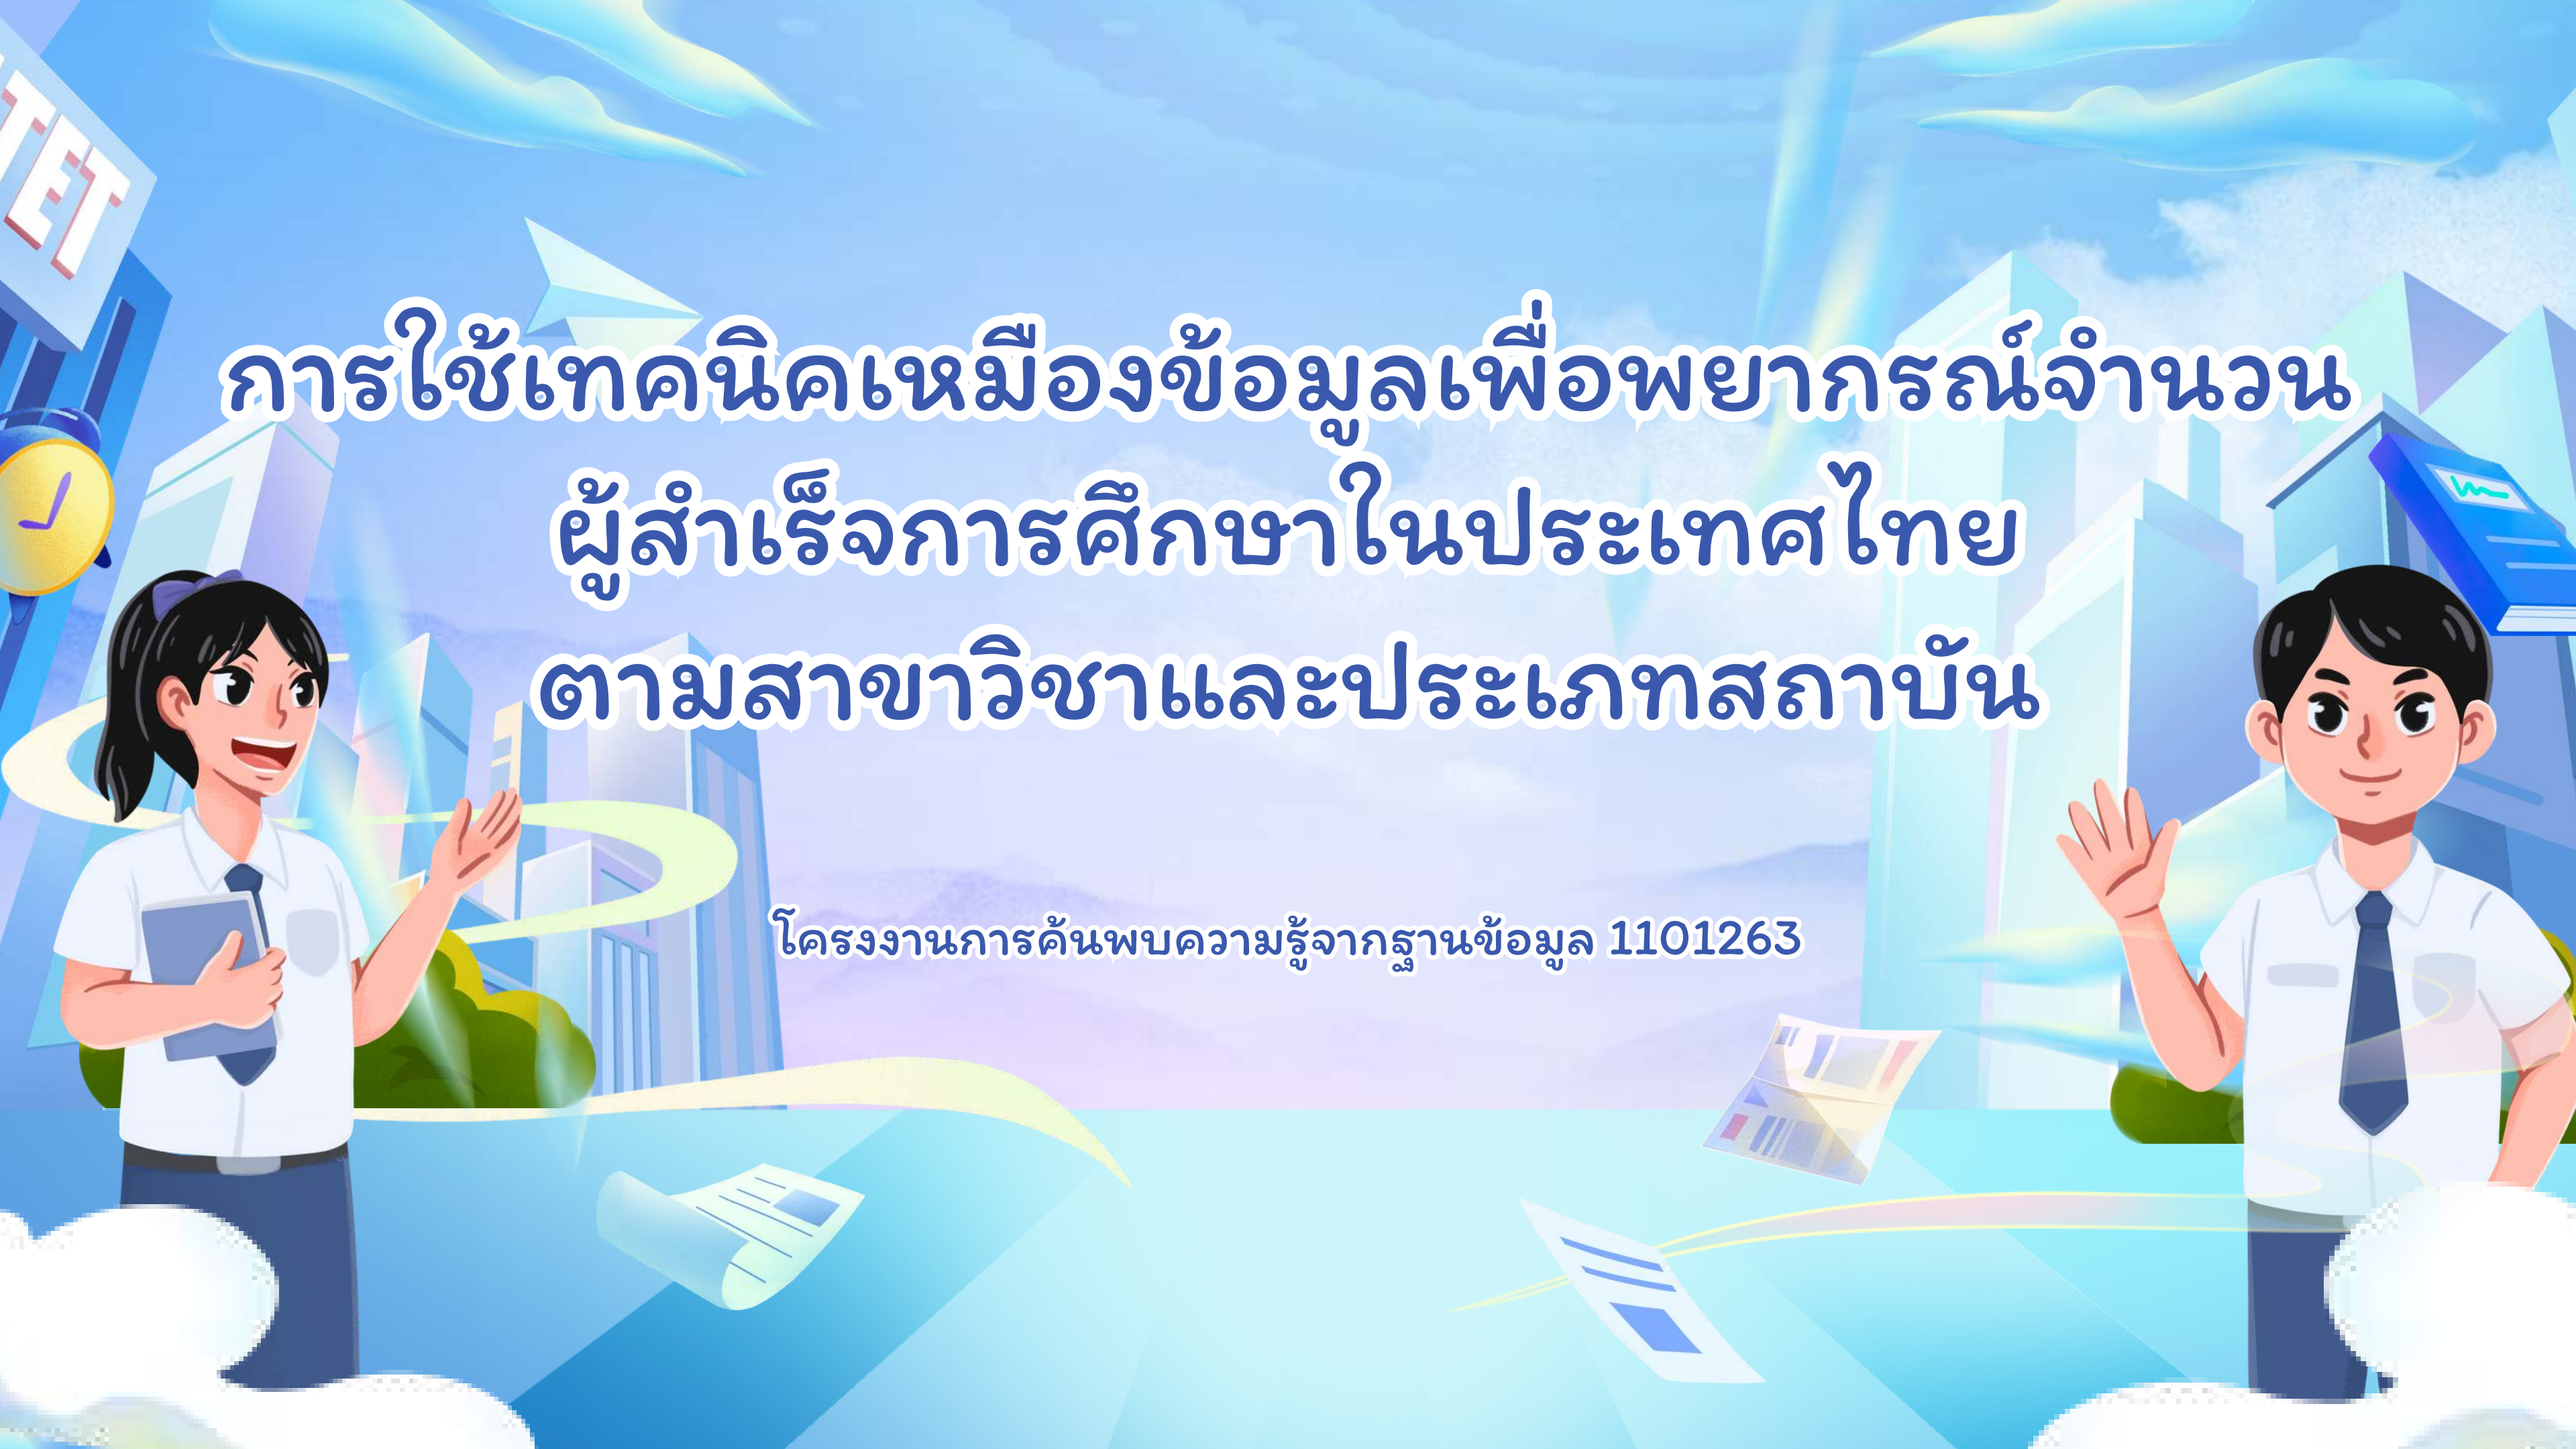
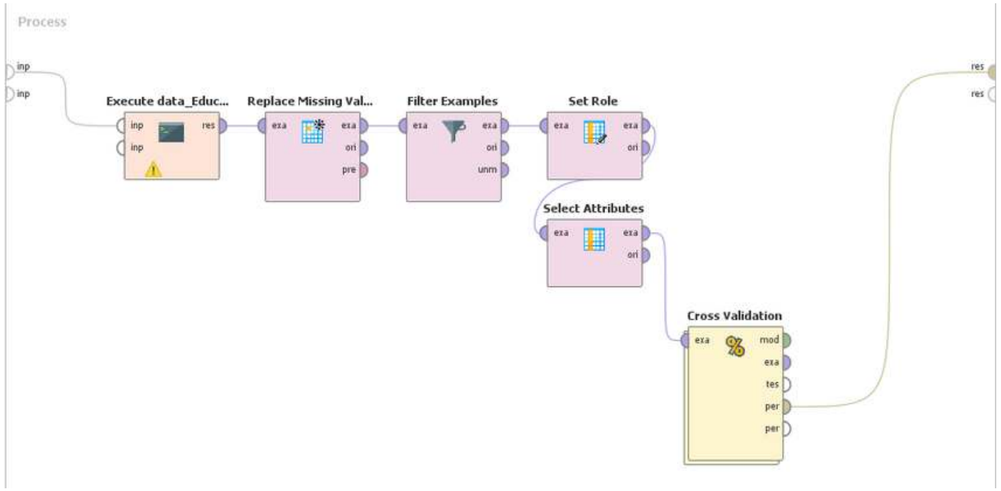


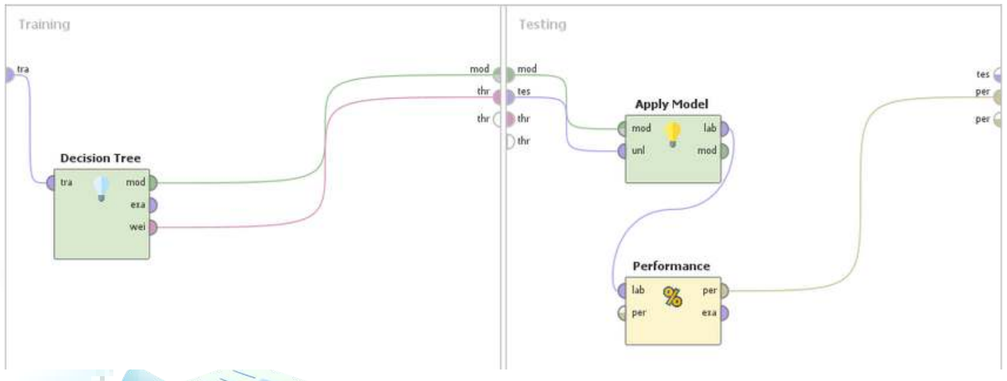
# การใช้เทคนิคเหมืองข้อมูลเพื่อพยากรณ์จำนวนผู้สำเร็จการศึกษาในประเทศไทยตามสาขาวิชาและประเภทสถาบัน

โครงงานการค้นพบความรู้จากฐานข้อมูล 1101263

# ต้นไม้ตัดสินใจ (Decision Tree)

## สร้างโมเดลโดยใช้โปรแกรม Rapidminer



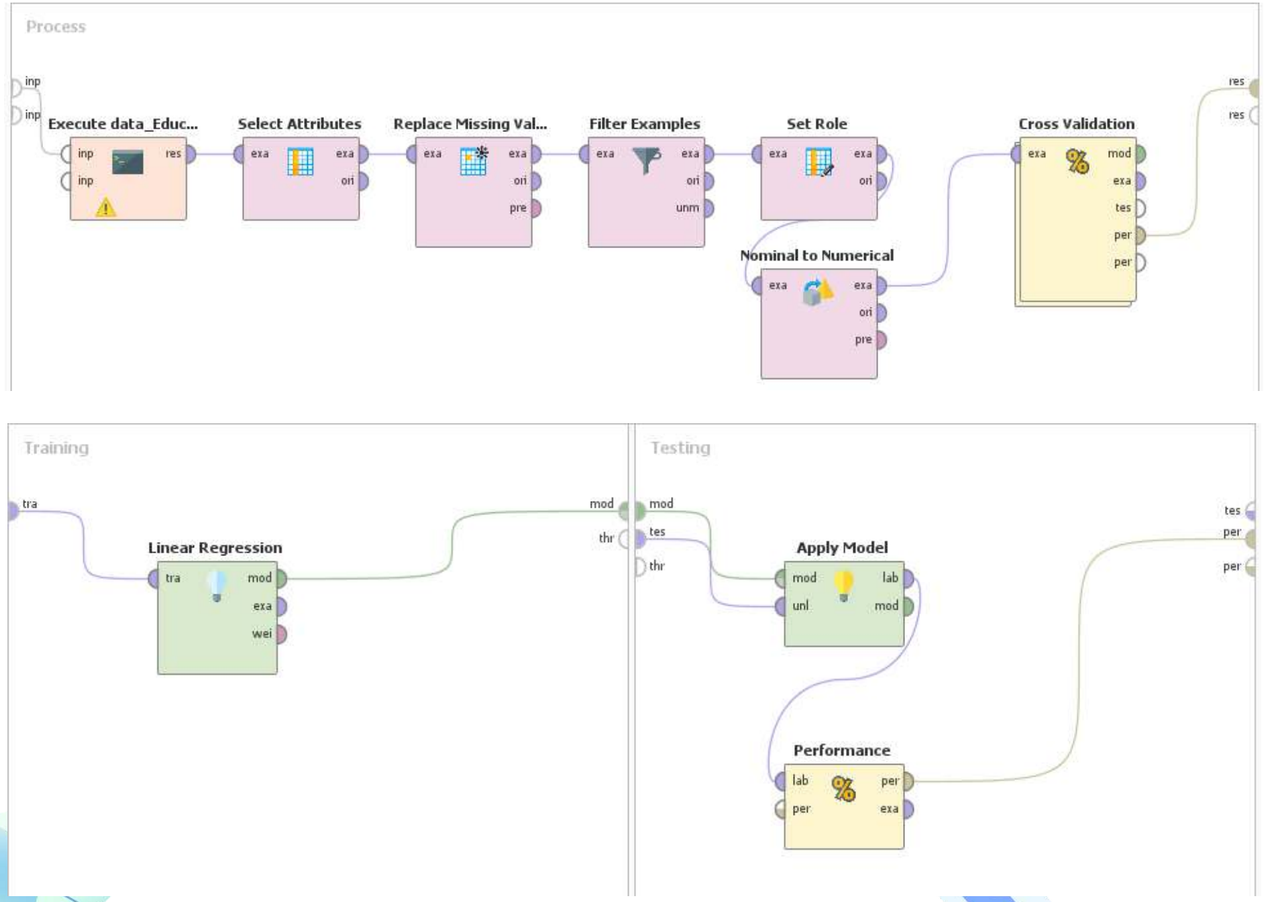

## ผลลัพธ์

PerformanceVector

- root_mean_squared_error: 36.584 +/- 9.219 (micro average: 37.615 +/- 0.000)
  - ค่าความคลาดเคลื่อนอยู่ในระดับสูงและมีความแปรปรวนมากสะท้อนถึงความไม่เสถียรของโมเดล
- absolute_error: 18.171 +/- 1.162 (micro average: 18.171 +/- 32.935)
  - ค่าความคลาดเคลื่อนเฉลี่ยอยู่ในระดับปานกลางและมีความคงที่ และการที่ค่า RMSE สูงกว่า MAE มาก บ่งชี้ว่ามีค่าคลาดเคลื่อนขนาดใหญ่เกิดขึ้นในบางกรณี
- squared_correlation: 0.077 +/- 0.029 (micro average: 0.063)
  - โมเดลอธิบายความแปรปรวนของข้อมูลได้ประมาณ 8% แสดงให้เห็นว่าประสิทธิภาพของโมเดลอยู่ในระดับต่ำ

# การถดถอยเชิงเส้น (Linear Regression)

## สร้างโมเดลโดยใช้โปรแกรม Rapidminer



# การถดถอยเชิงเส้น (Linear Regression)

## ผลลัพธ์

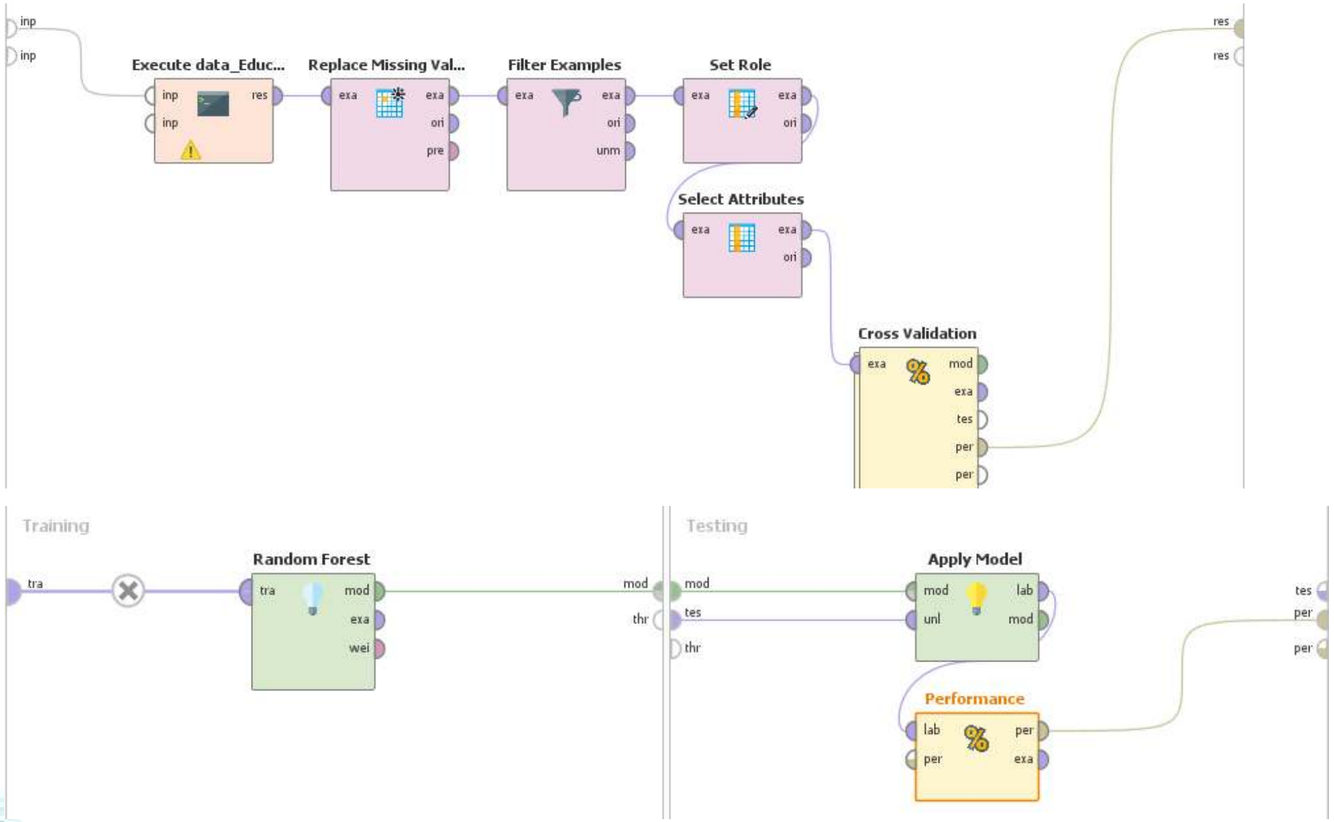
- root_mean_squared_error: 35.644 ± 8.784 (micro average: 36.606 ± 0.000)
  - ค่าความคลาดเคลื่อนอยู่ในระดับสูง และมีความแปรปรวนค่อนข้างมาก
- absolute_error: 17.612 ± 0.983 (micro average: 17.612 ± 32.090)
  - ค่าความคลาดเคลื่อนเฉลี่ยอยู่ในระดับปานกลางถึงสูง
- squared_correlation: 0.124 ± 0.019 (micro average: 0.113)
  - โมเดลอธิบายความแปรปรวนของข้อมูลได้ประมาณ 12% แสดงว่าประสิทธิภาพของโมเดลอยู่ในระดับต่ำ

```
LinearRegression
- 2.142 * ISCED_BROAD = Agriculture, forestry,fisheries and veterinary
+ 1.847 * ISCED_BROAD = Arts and humanities
+ 18.102 * ISCED_BROAD = Business, administration and law
+ 6.552 * ISCED_BROAD = Education
+ 5.560 * ISCED_BROAD = Health and welfare
- 3.501 * ISCED_BROAD = Natural sciences,mathematics and statistics
+ 3.962 * ISCED_BROAD = Services
+ 9.560 * ISCED_BROAD = Social sciences, journalism and information
+ 12.396 * UNIV_TYPE_NAME = มหาวิทยาลัยของรัฐ
+ 5.164 * UNIV_TYPE_NAME = มหาวิทยาลัยเทคโนโลยีราชมงคล
+ 12.684 * UNIV_TYPE_NAME = มหาวิทยาลัยในกำกับรัฐ
+ 9.495 * UNIV_TYPE_NAME = มหาวิทยาลัยเอกชน
+ 20.963 * UNIV_TYPE_NAME = สถาบันเอกชน
+ 47.926 * UNIV_TYPE_NAME = มหาวิทยาลัยรัฐไม่จำกัดรับ
+ 1.635 * UNIV_TYPE_NAME = มหาวิทยาลัยราชภัฏ
+ 11.295 * UNIV_TYPE_NAME = วิทยาลัยชุมชน
+ 5.857 * UNIV_TYPE_NAME = สถานศึกษานอกสังกัดฯ
- 21.073 * LEV_NAME_TH = ปริญญาโท
- 25.330 * LEV_NAME_TH = ปริญญาเอก
- 12.027 * LEV_NAME_TH = ประกาศนียบัตรวิชาชีพชั้นสูง
- 18.285 * LEV_NAME_TH = อนุปริญญา
- 18.413 * LEV_NAME_TH = ประกาศนียบัตรบัณฑิตชั้นสูง
+ 20.321 * LEV_NAME_TH = ประกาศนียบัตรบัณฑิต
+ 0.915 * LEV_NAME_TH = ประกาศนียบัตร
+ 9.234 * GENDER_NAME = หญิง
+ 7.970
```

1) สาขาวิชา (ISCED_BROAD)
   สาขาที่ทำให้ค่าทำนายเพิ่มขึ้น เช่น Business, Education, Health, Social sciences
   สาขาที่ทำให้ค่าทำนายลดลง เช่น Agriculture, Natural sciences
2) ประเภทมหาวิทยาลัย (UNIV_TYPE_NAME)
   มหาวิทยาลัยรัฐไม่จำกัดรับ → ส่งผลให้ค่าทำนายสูงขึ้นมากที่สุด
   สถาบันเอกชน และมหาวิทยาลัยของรัฐ → มีผลเพิ่มค่าทำนายในระดับสูง
3) ระดับการศึกษา (LEV_NAME_TH)
   ระดับปริญญาโท และปริญญาเอก → ส่งผลให้ค่าทำนายลดลงมาก
   ระดับประกาศนียบัตรบางประเภท → เพิ่มค่าทำนาย
   ระดับอื่นๆ มีผลเพิ่มหรือลดตามชนิดใบประกาศ
4) เพศ (GENDER_NAME)
   เพศหญิง → ค่าทำนายเพิ่มขึ้นเล็กน้อย

# เทคนิคป่าไม้สุ่ม (Random Forest)

## สร้างโมเดลโดยใช้โปรแกรม RAPIDMINER




## ผลลัพธ์

### PerformanceVector

```
PerformanceVector:
root_mean_squared_error: 33.995 +/- 7.000 (micro average: 34.638 +/- 0.000)
absolute_error: 14.884 +/- 0.744 (micro average: 14.884 +/- 31.277)
squared_correlation: 0.222 +/- 0.059 (micro average: 0.221)
```

- Root Mean Squared Error (RMSE)

  = 33.995 ซึ่งต่ำกว่า Regression Tree แสดงว่าโมเดลมีความแม่นยำมากขึ้น

- Absolute Error (MAE)

  = 14.884 ผลทำนายคลาดเคลื่อนจากค่าจริงประมาณ 15 หน่วย

- Squared Correlation ($R^2$)

  = 0.222 สูงกว่า Regression Tree อย่างชัดเจน แสดงว่า Random Forest สามารถอธิบายข้อมูลได้ดีกว่า

# ตารางเปรียบเทียบโมเดล

| ตัววัดประสิทธิภาพ | Decision Tree | Linear Regression | Random Forest |
|---|---|---|---|
| Root Mean Squared Error (RMSE) | 36.584 +/- 9.219 | 35.644 +/- 8.784 | 33.995 +/- 7.000 |
| Absolute Error | 18.171 +/- 1.162 | 17.612 +/- 0.983 | 14.884 +/- 0.744 |
| Squared Correlation (R2) | 0.077 +/- 0.029 | 0.124 +/- 0.019 | 0.222 +/- 0.059 |

# สรุปผลที่ได้จากการทำ Data mining

สรุปผลการทำ data mining พบว่า Random Forest เป็นเทคนิคที่เหมาะสมที่สุดในการพยากรณ์จำนวนผู้สำเร็จการศึกษา โดยให้ประสิทธิภาพสูงสุดเมื่อเทียบกับวิธีอื่น จากค่าความคลาดเคลื่อนที่ต่ำที่สุด RMSE = 33.995 และ Absolute Error = 14.884 และมีค่าสัมประสิทธิ์การตัดสินใจ Squared Correlation = 0.222 ซึ่งสามารถอธิบายความผันแปรของจำนวนผู้สำเร็จการศึกษาได้ดีที่สุดจากปัจจัยด้านปีการศึกษา สาขาวิชา ประเภทมหาวิทยาลัย ระดับการศึกษา และเพศ

ผลการวิจัยชี้ให้เห็นว่า Random Forest มีความแม่นยำและเสถียรในการวิเคราะห์ข้อมูลการศึกษาที่มีความหลากหลาย และสามารถนำไปใช้เป็นเครื่องมือสนับสนุนการตัดสินใจในการวางแผนกำลังคน การจัดการหลักสูตร และการกำหนดนโยบายทางการศึกษาให้สอดคล้องกับความต้องการของตลาดแรงงานในอนาคตได้อย่างมีประสิทธิภาพ